FACULTAD DE CIENCIAS BIOLOGICAS
Universidad de Concepción

TRANSCRIPTOMICS

ENSAMBLE DE NOVO

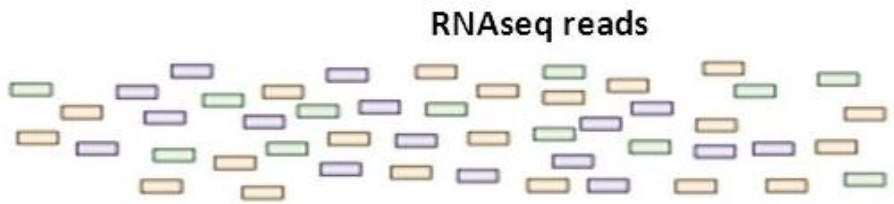


ESTEFANÍA TARIFEÑO PHD.

FACULTAD DE CS. BIOLÓGICAS

Reconstrucción de transcritos

El ensamble *de novo* de transcriptomas ha permitido el estudio de organismos no modelos para los cuales su genoma de referencia no se encuentra disponible



Read Pre-processing

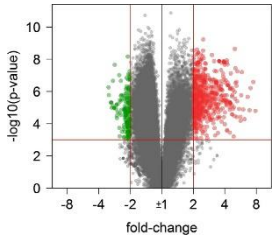


ensamble *de novo*

Contigs



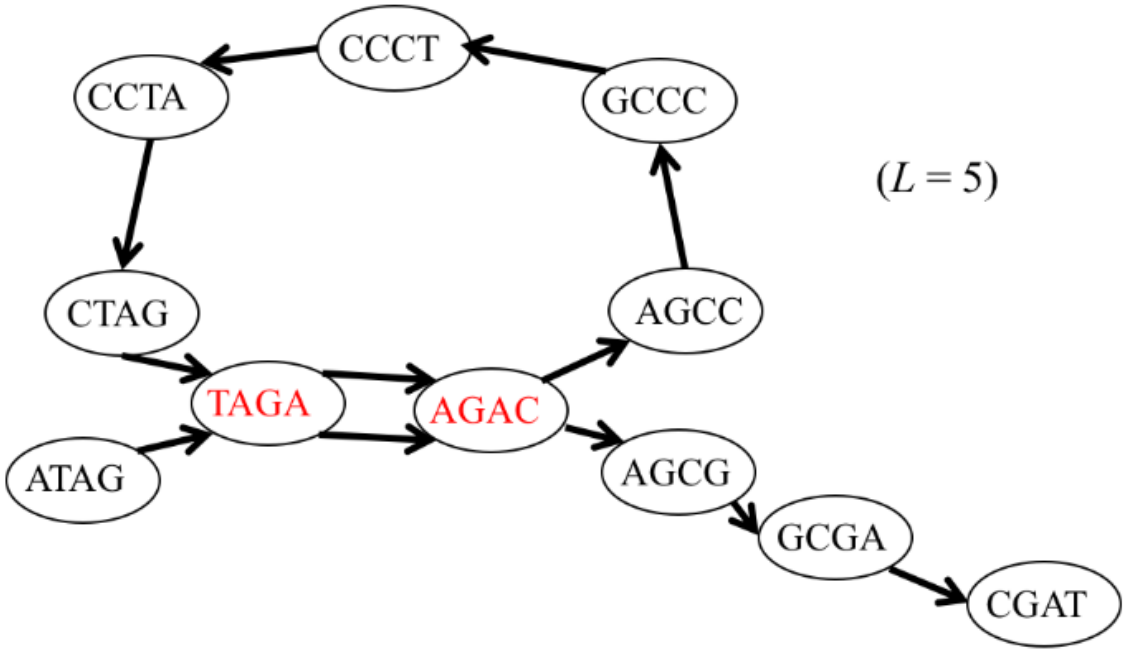
Estimación de expresión



Test DE

De novo RNA-seq Assembly

La aproximación mayormente utilizada para realizar ensamble de transcriptoma es el **grafo De Bruijn** (De Bruijn Graphs). Que es especialmente útil para ensamblar **reads cortos**.



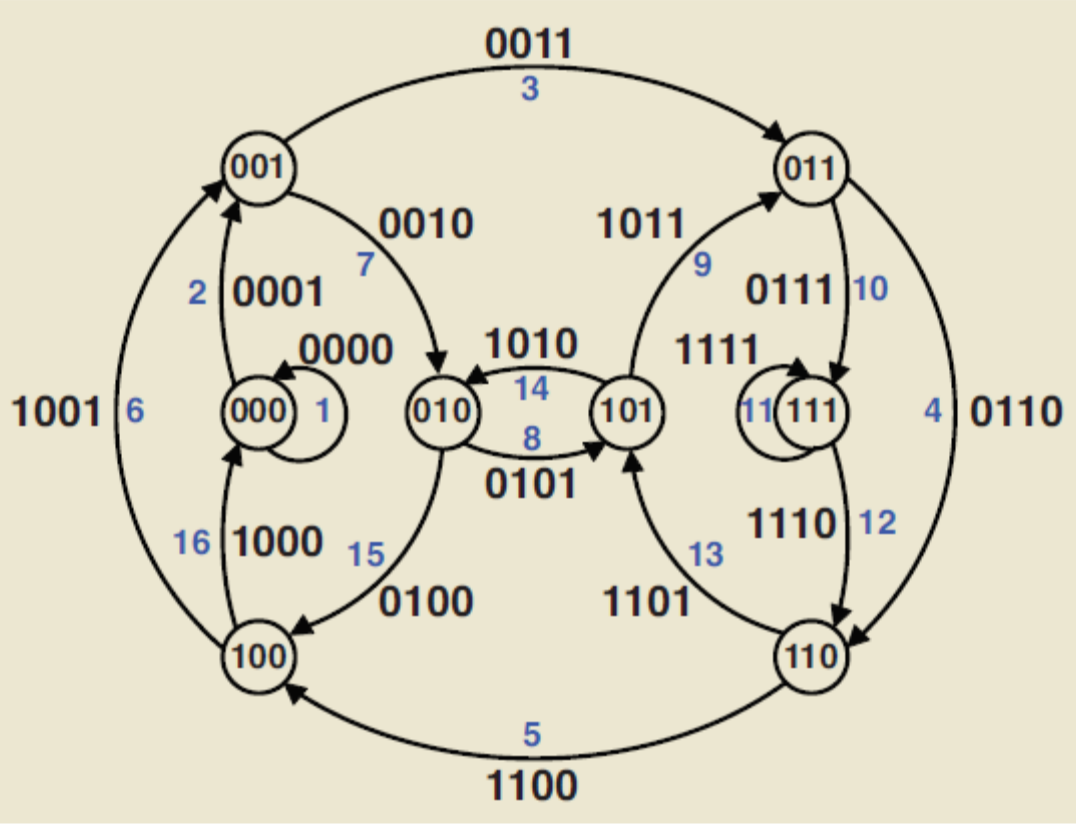
Origen del mapa de Bruijn

El matemático alemán Nicolaas de Bruijn se interesó en el problema de la "superstring" que consistía en encontrar una "superstring" circular que contenga todas las "substring" posibles de largo *k (K-mer)* para un alfabeto dado.

Por ejemplo, si k=4 y el alfabeto binario son los dígitos 0 y 1.

Todas las combinaciones posibles son 0000, 0001, 0011, 0110, 1100, 1001, 0010, 0101, 1011, 0111, 1111, 1110, 1101, 1010, 0100, 1000.

¿Como podemos construir esta superstring circular?

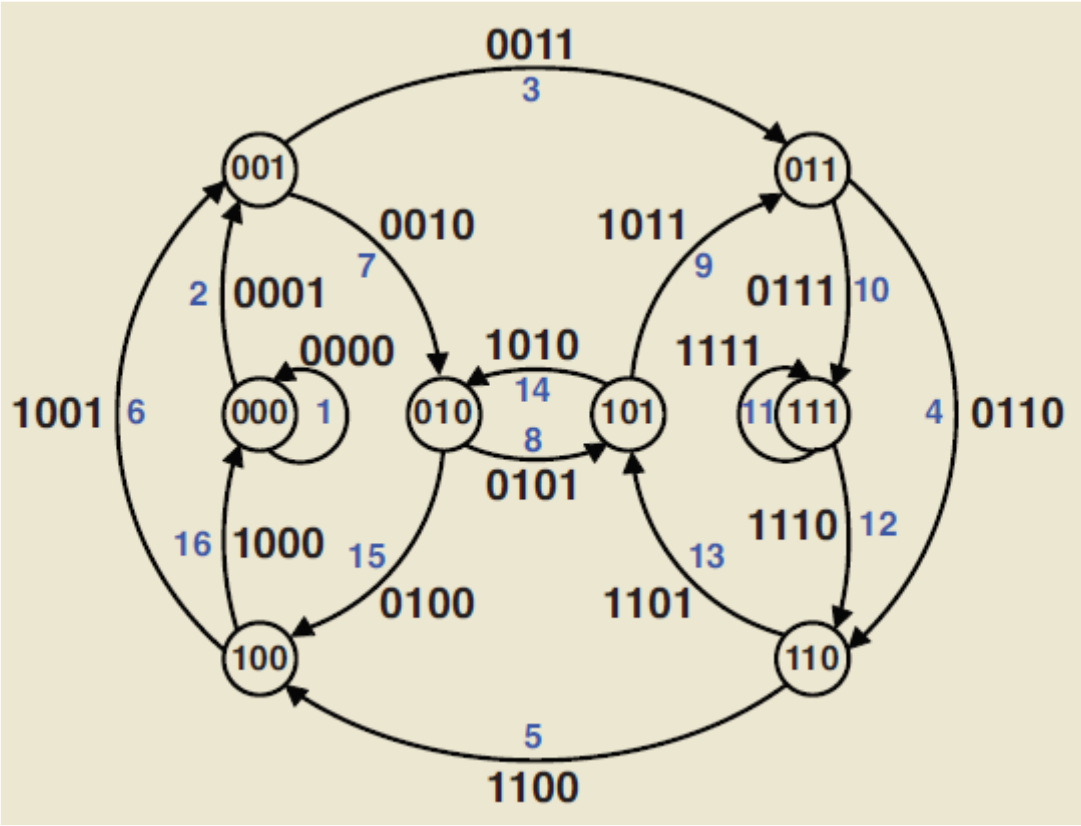


Origen del mapa de Bruijn

Tomando el método de Euler (la solución del problema de los puentes de konigsberg) se construye un gráfico donde:

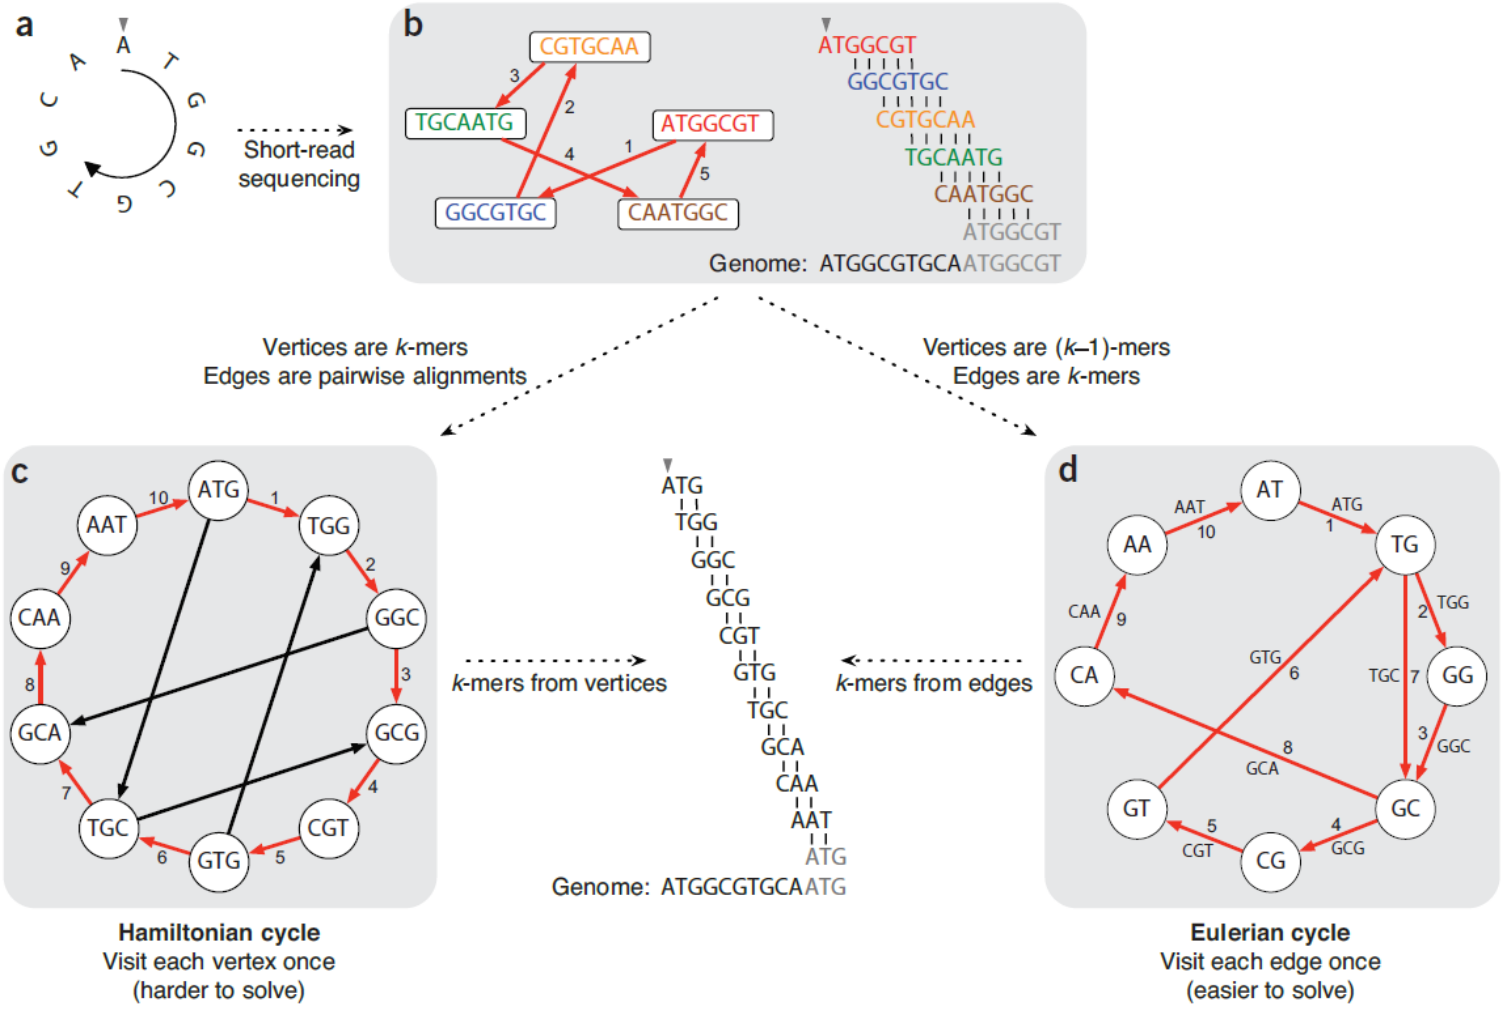
- Cada posible [k-1]mero se asigna a un **nodo. Cada nodo es único**.
- Los nodos se unen a través de **vértices** si existe un k-mer que pueda ser reconstruido desde la unión de los nodos. Los vértices contienen cada kmero.
- Estos gráficos son direccionales, pasando solo una vez por cada vértice (Eulerian walk)

Todas las combinaciones posibles son 0000, 0001, 0011, 0110, 1100, 1001, 0010, 0101, 1011, 0111, 1111, 1110, 1101, 1010, 0100, 1000.



Entonces, las superstring circular es 0000110010111101

Grafo De Bruijn y ensamble



Existen dos maneras de ensamblar:

Ciclos Hamiltonianos. Pasa por cada **nodo una vez** y termina en el nodo que comenzó. Es difícil de resolver, ya que los kmeros son deducidos desde los nodos (resultando en gráficos de "mayor tamaño") y no es utilizado en la actualidad por ningún ensamblador

Ciclos Eulerianos. Pasa por cada los vértices solo una vez. Los kmeros se deducen desde los vértices, pudiendo pasar varias veces por un mismo nodo. Esto resulta en una gráfica más simple.

Construcción del gráfico con secuencias

- Los reads son divididos en ***k-mers*** (secuencias cortas de tamaño k) y que corresponden a los vértices en el gráfico.

- Los **nodos** en el gráfico corresponden a las secuencias (k-1)-mers (edges) y se definen por el overlap entre k-2 nucleótidos

Read ATAGACCCTAGACGAT

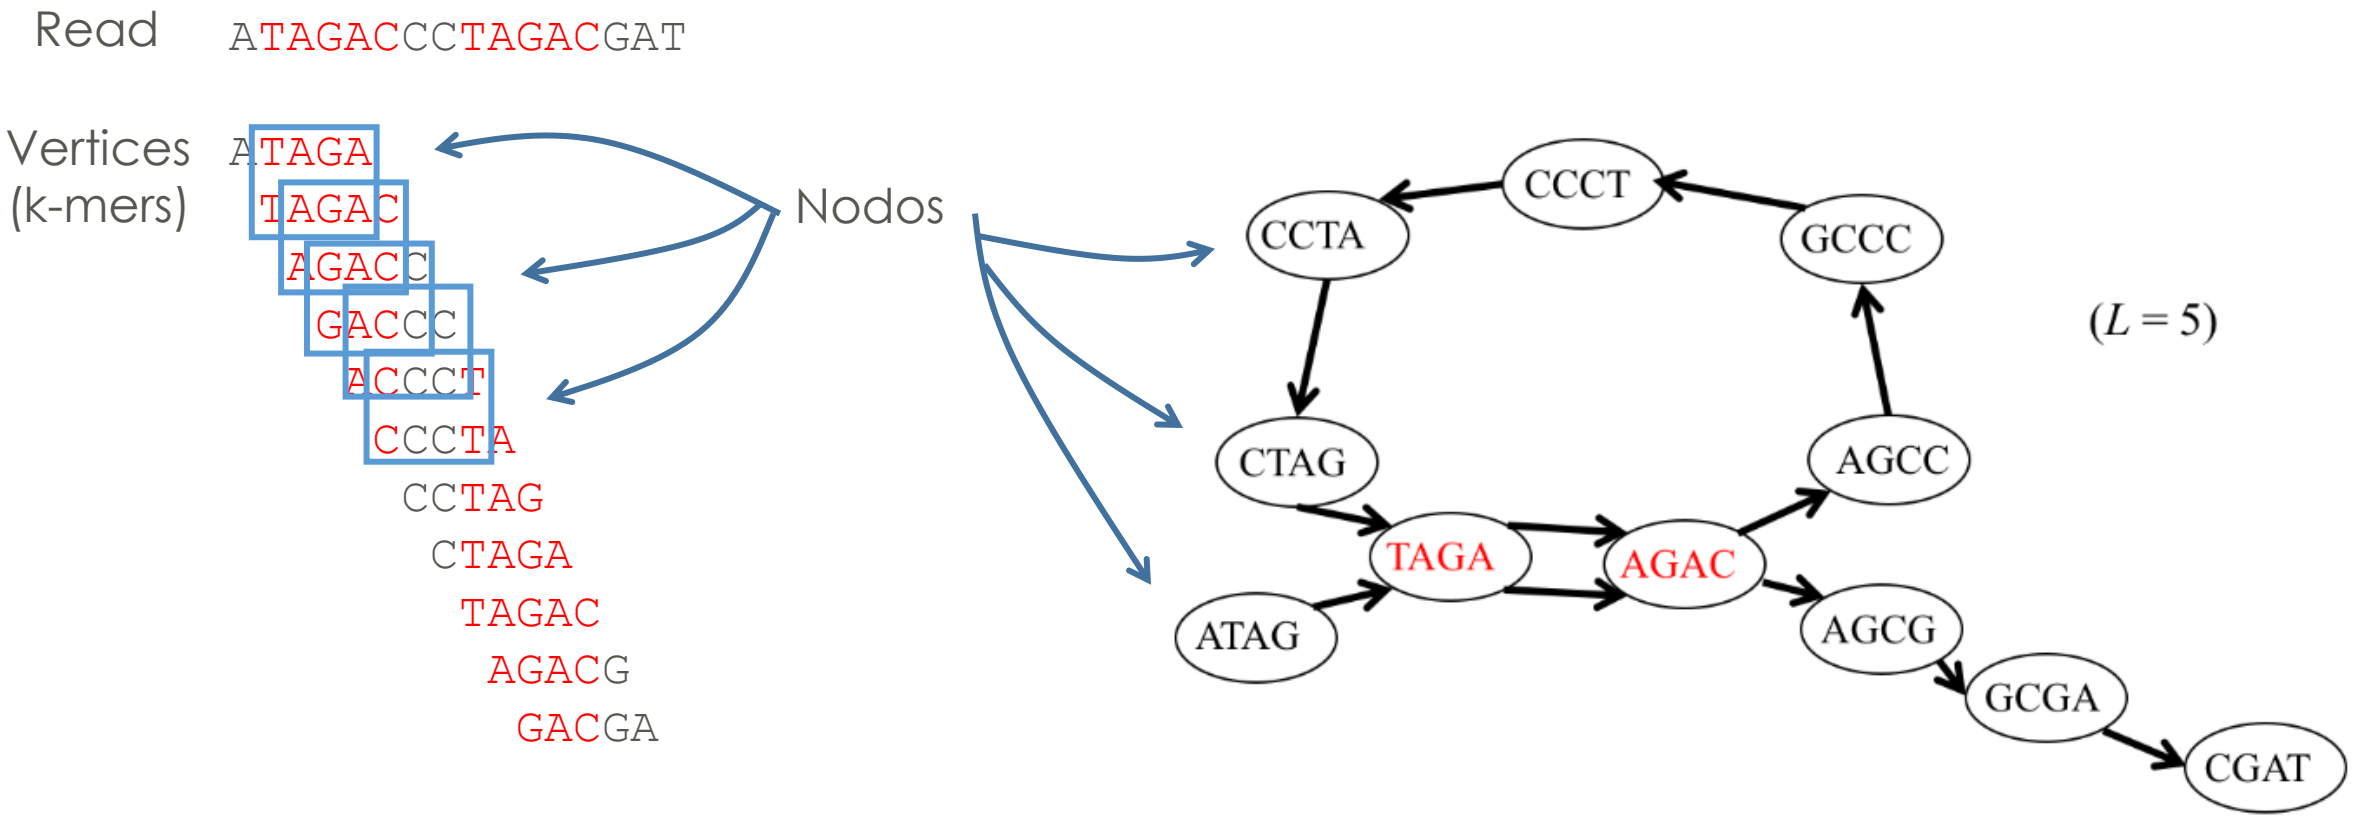
Vertices (k=5)

```
ATAGA
 TAGAC
  AGACC
   GACCC
    ACCCT
     CCCTA
      CCTAG
       CTAGA
        TAGAC
         AGACG
          GACGA
```

Construcción del gráfico con secuencias

- Los reads son divididos en ***k-mers*** (secuencias cortas de tamaño k) y que corresponden a los vértices en el gráfico.

- Los **nodos** en el gráfico corresponden a las secuencias (k-1)-mers (edges) y se definen por el overlap entre k-2 nucleótidos



Construcción del gráfico con secuencias

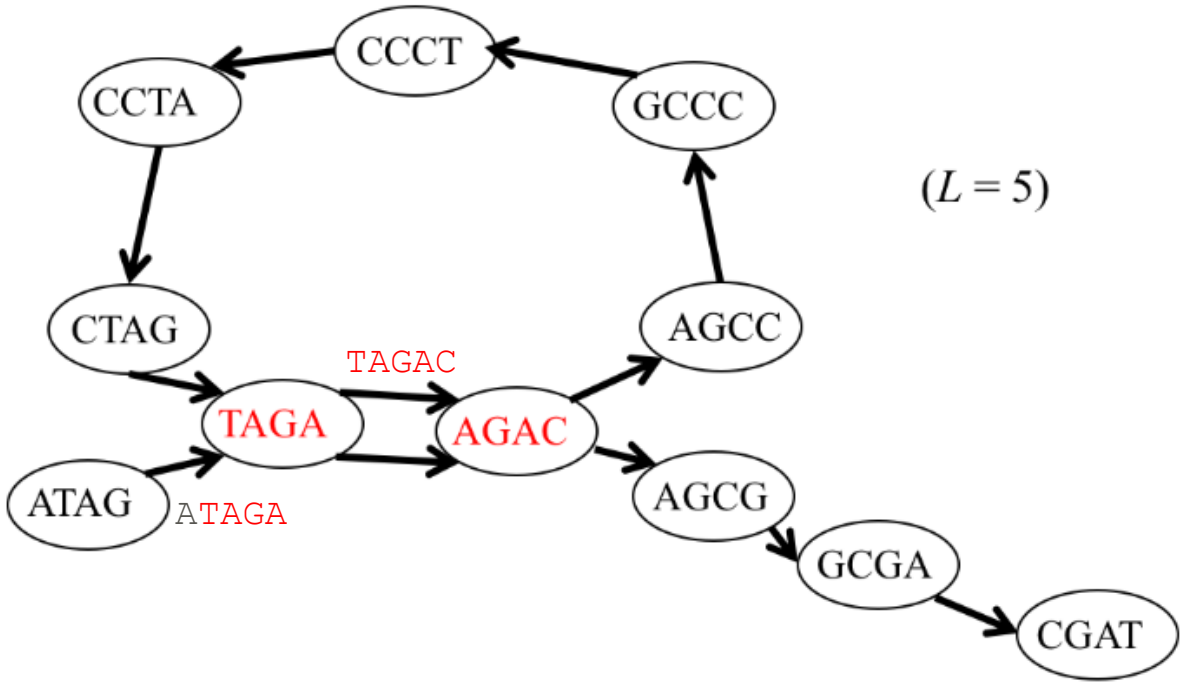
- Los reads son divididos en ***k-mers*** (secuencias cortas de tamaño k) y que corresponden a los vértices en el gráfico.

- Los **nodos** en el gráfico corresponden a las secuencias (k-1)-mers (edges) y se definen por el overlap entre k-2 nucleótidos

Read ATAGACCCTAGACGAT

Vertices (k-mers)

ATAGA
TAGAC
AGACC
GACCC
ACCCT
CCCTA
CCTAG
CTAGA
TAGAC
AGACG
GACGA



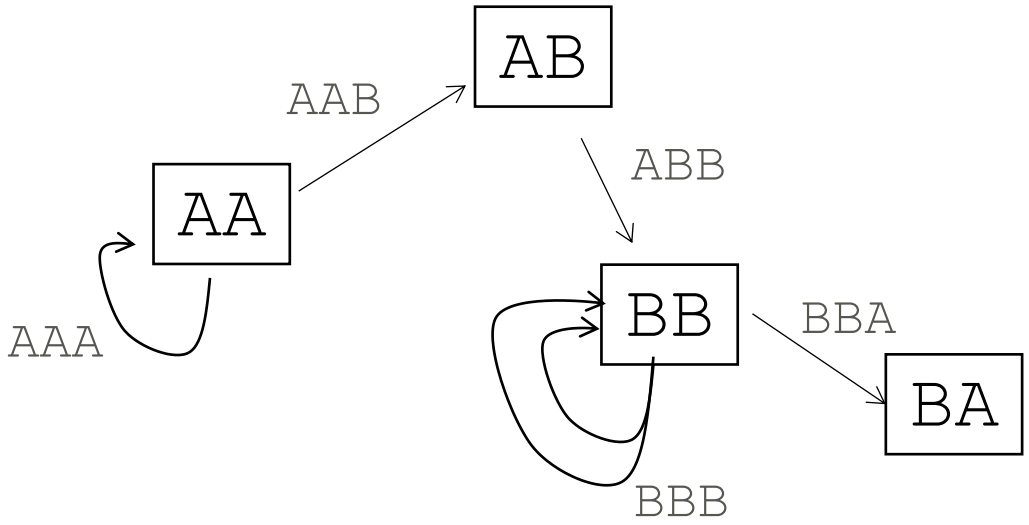
Ejercicio – Construyan el gráfico de bruijn

Read AAABBBBA

Vértices (3-mers) AAA, AAB, ABB, BBB, BBB, BBA

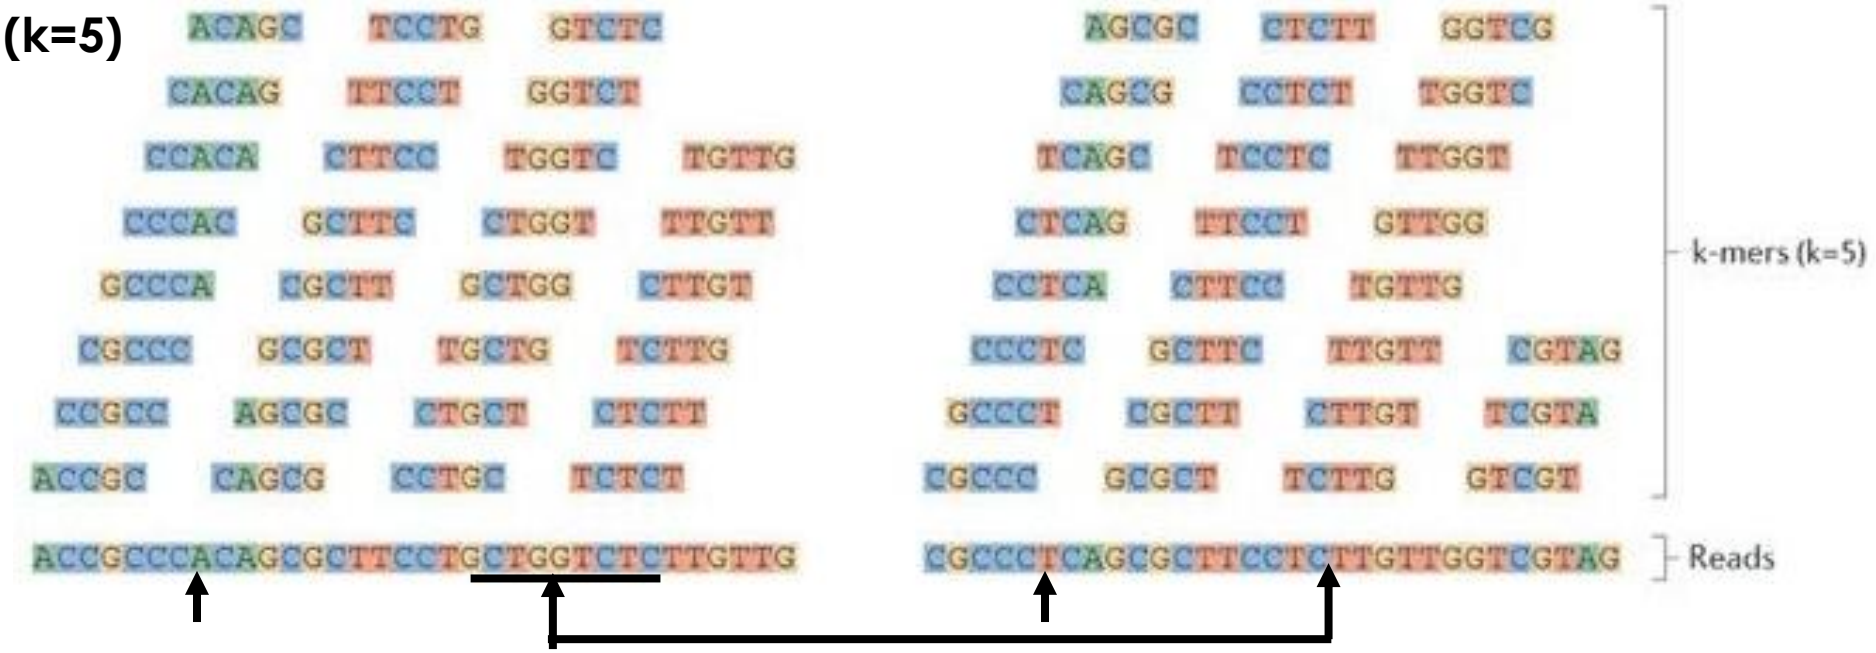
Nodos (2-mers) AA,AA, AA,AB, AB,BB, BB,BB, BB,BB, BB,BA

****recordar cada nodo es único**



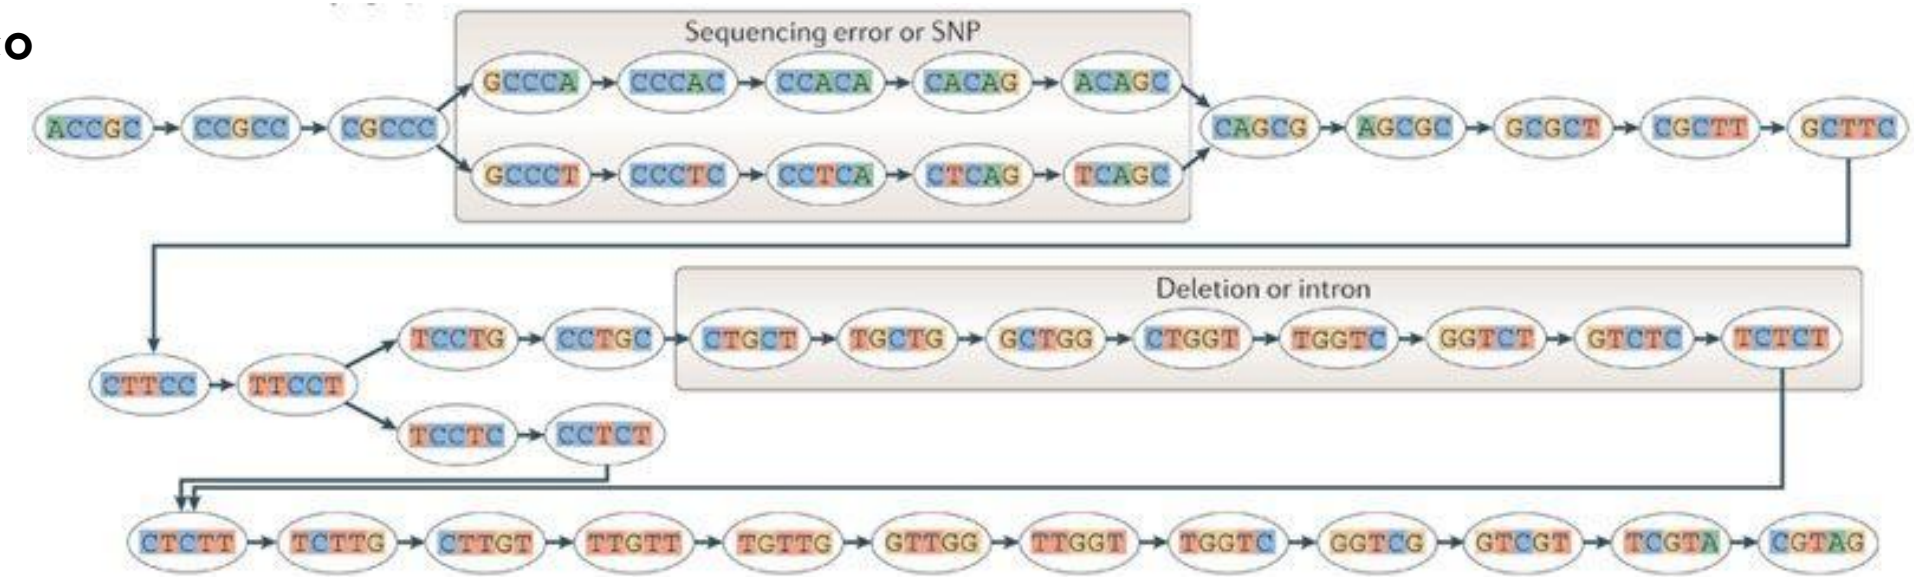
Ensamble de secuencias con SNPs usando el gráfico De Bruijn

1) Extraer los k-mers (k=5)



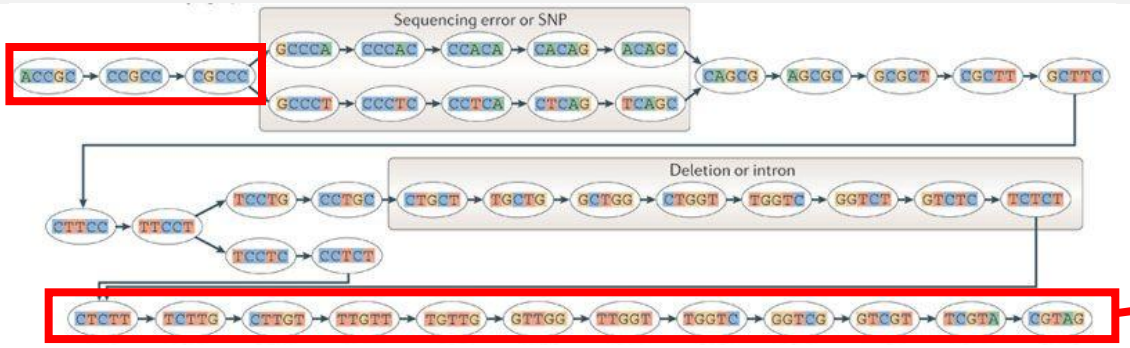
Aparición de un SNP & Indels

2) Generar el Gráfico

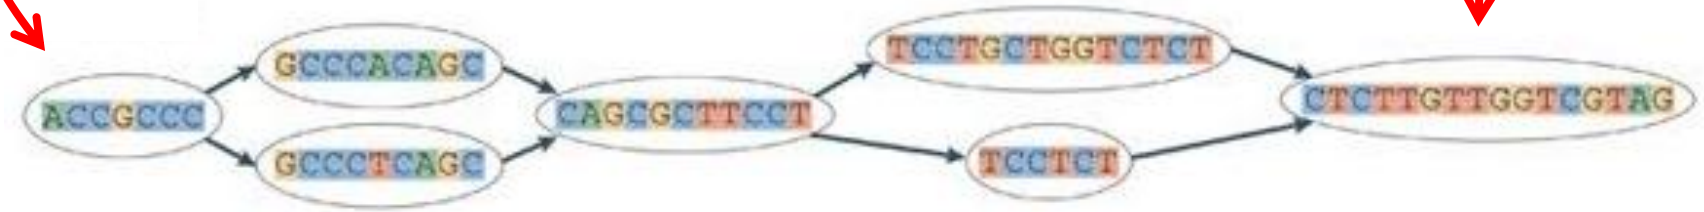


Ensamble de secuencias usando el gráfico De Bruijn

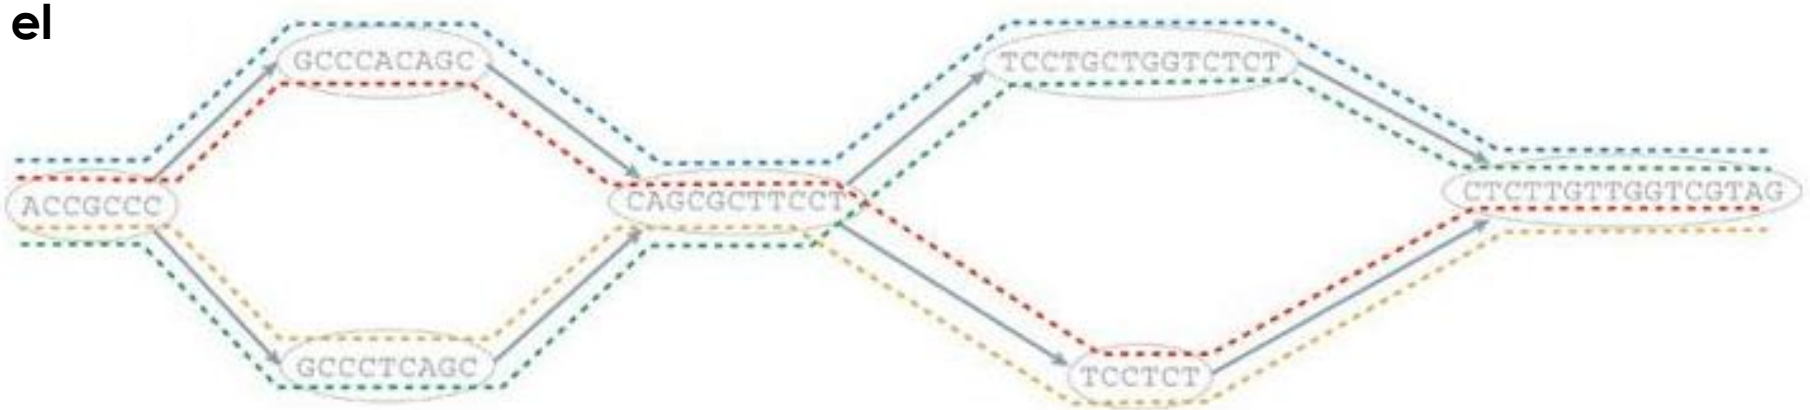
2) Generar el Gráfico



3) Colapsar el gráfico

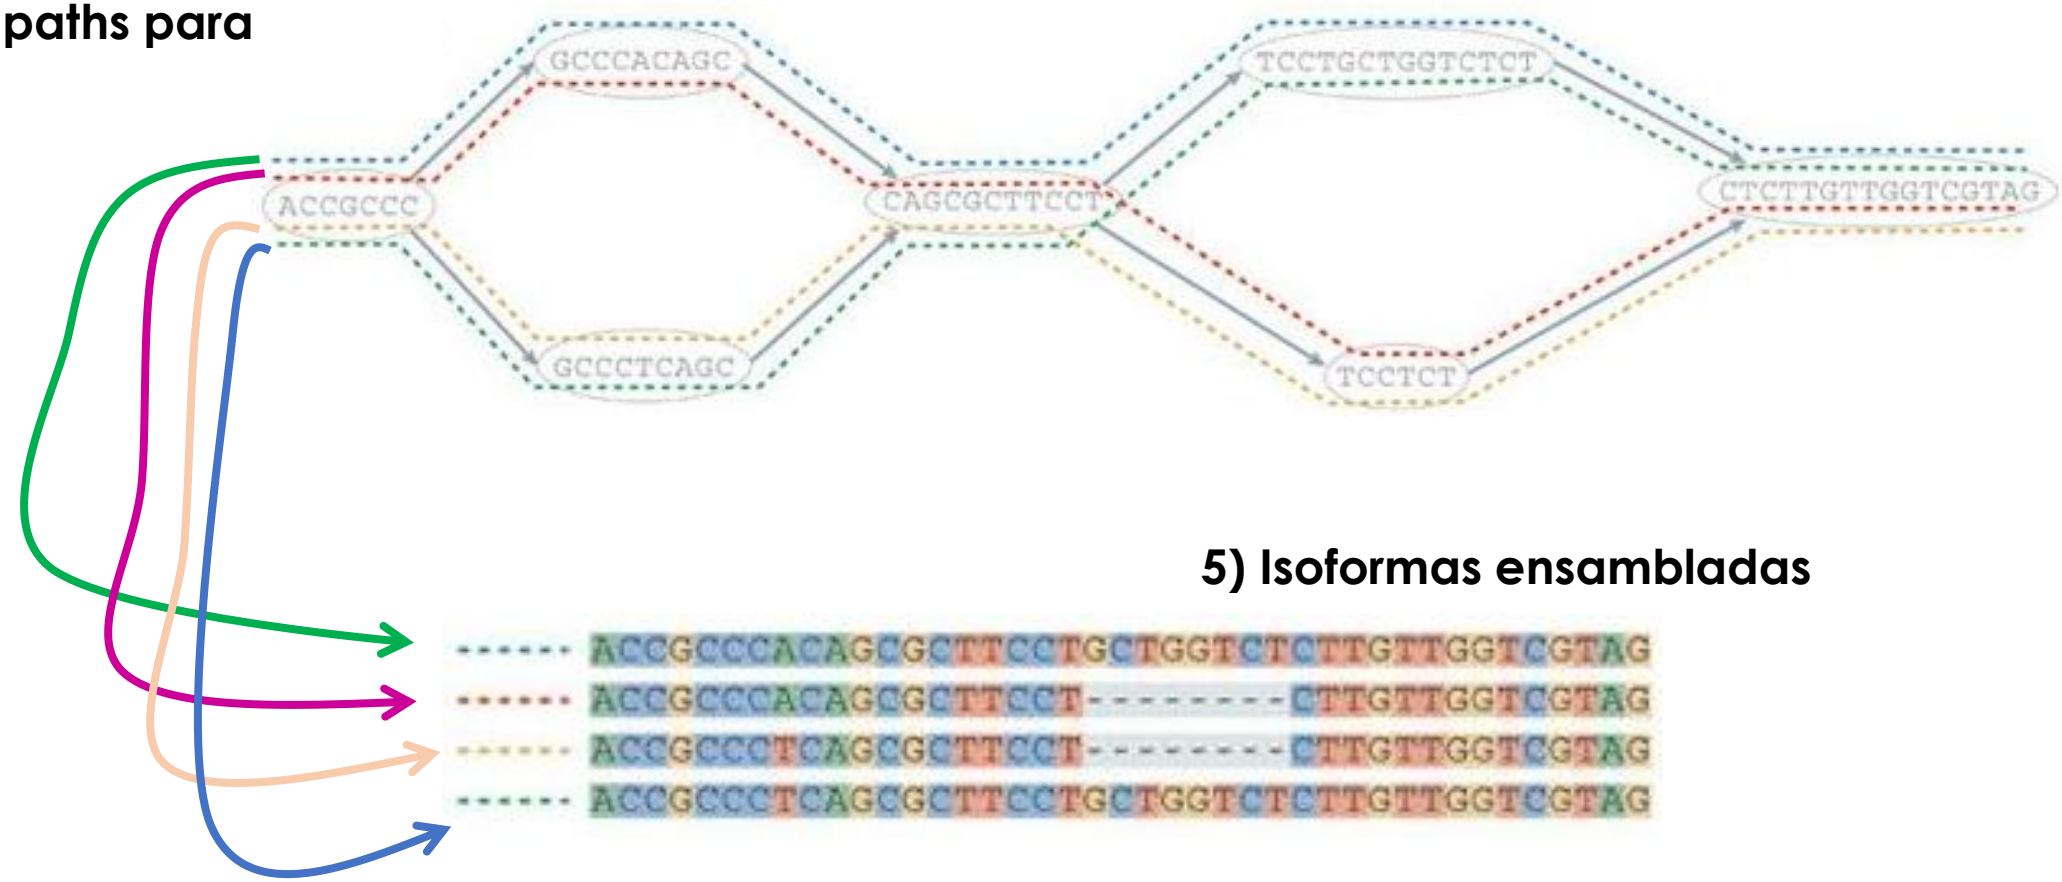


4) Selección de paths para el ensable



Ensamble de secuencias usando el gráfico De Bruijn

4) Selección de paths para ensable



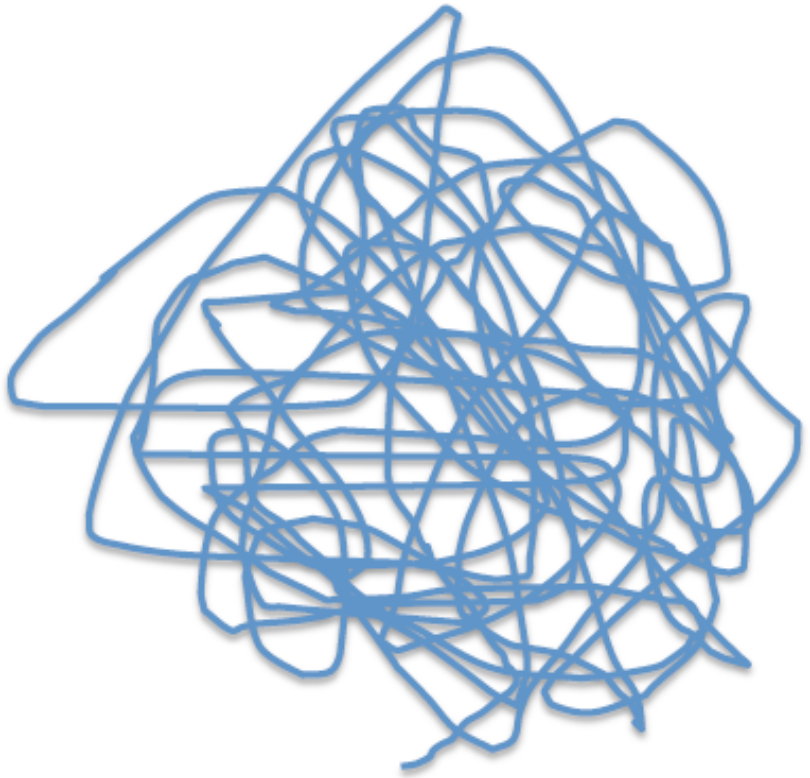
5) Isoformas ensambladas

```
------ ACCGCCCACAGCGCTTCCTGCTGGTCTCTTGTTGGTCGTAG
------ ACCGCCCACAGCGCTTCCT--------CTTGTTGGTCGTAG
------ ACCGCCCTCAGCGCTTCCT--------CTTGTTGGTCGTAG
------ ACCGCCCTCAGCGCTTCCTGCTGGTCTCTTGTTGGTCGTAG
```

Contraste entre ensamble genómico y transcriptómico

Ensamble Genómico

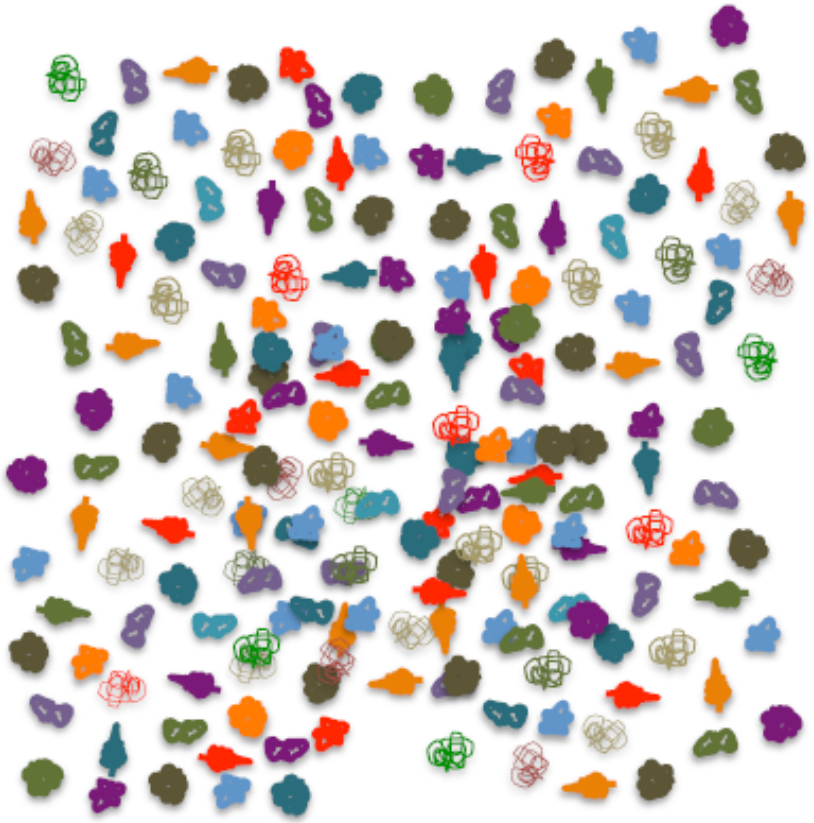
Se obtiene un solo gráfico masivo



El cromosoma completo se encuentra representado por un solo gráfico (idealmente)

Ensamble Transcriptómico

Se obtienen miles de gráfico pequeños



Se obtiene un gráfico por transcrito/isoforma expresada (idealmente)

Ensambladores *de novo*

SOAPdenovo-Trans

Trans-AbySS

Velvet/Oases

Trinity

BinPacker

SPAdes

(Geniza et al., 2017, Current Plant Biology)

Ensamblador TRINITY

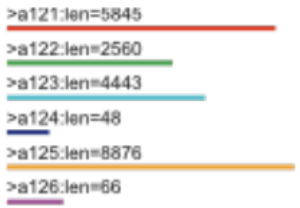


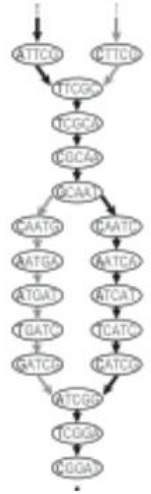




Raw reads → Contigs → Gráficos De Bruijn → Transcritos + Isoformas







Miles de gráficos separados

Algoritmo utilizado por Inchworm



- Descompone todos los reads en Kmers que sobrelapan
  → hashtable(kmer, count)
- Identifica como Kmers "semilla" (seed) aquellos que son más abundantes

Kmer Catalog (hashtable)

Kmer	Count among all reads
AATGTGA	4
ATGTGAA	2
TGTGAAA	1
GATTACA	9

Algoritmo utilizado por Inchworm



- Descompone todos los reads en Kmers que sobrelapan
  → hashtable(kmer, count)
- Identifica como Kmers "semilla" (seed) aquellos que son más abundantes
- Extiende estos Kmers guiado por la cobertura

GATTACA

9

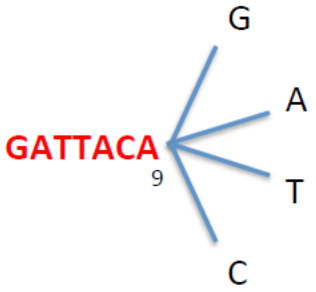
Kmer Catalog (hashtable)

Kmer	Count among all reads
AATGTGA	4
ATGTGAA	2
TGTGAAA	1
GATTACA	9

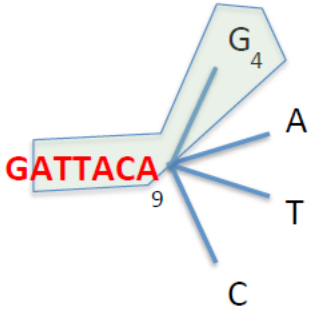
Algoritmo utilizado por Inchworm



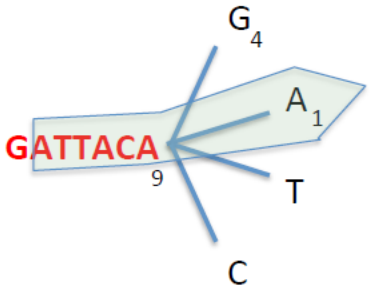
- Descompone todos los reads en Kmers que sobrelapan
  → hashtable(kmer, count)
- Identifica como Kmers "semilla" (seed) aquellos que son mas abundantes
- Extiende estos Kmers guiado por la cobertura



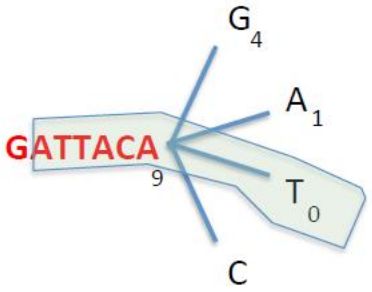
Algoritmo utilizado por Inchworm



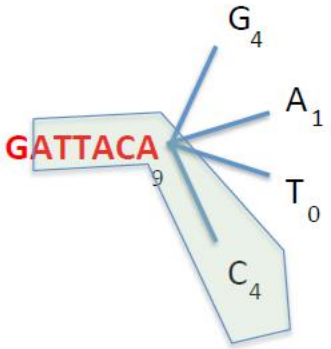
Algoritmo utilizado por Inchworm



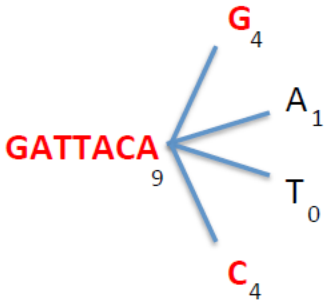
Algoritmo utilizado por Inchworm



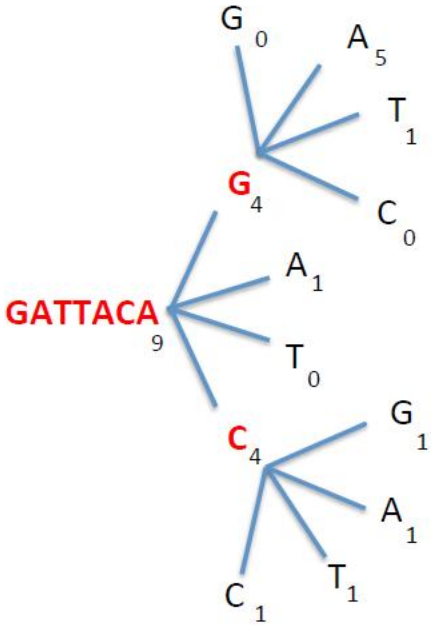
Algoritmo utilizado por Inchworm



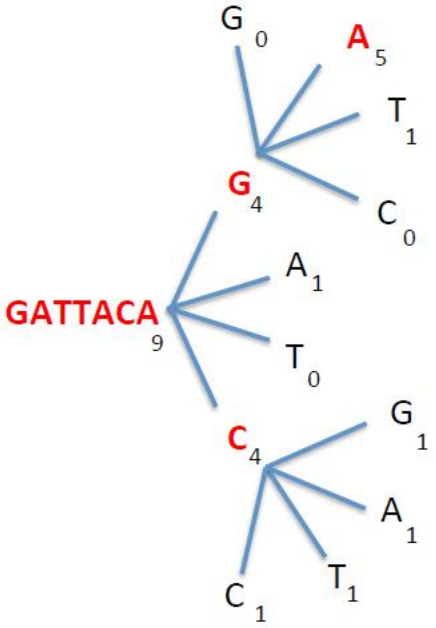
Algoritmo utilizado por Inchworm



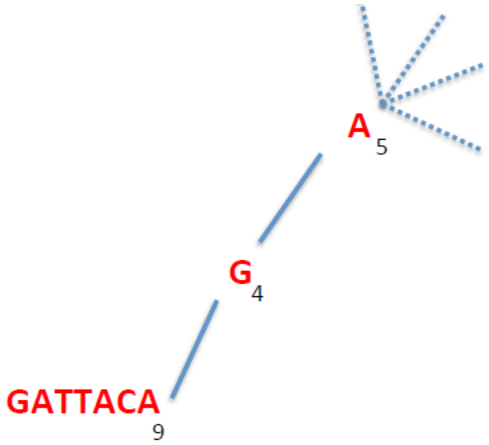
Algoritmo utilizado por Inchworm



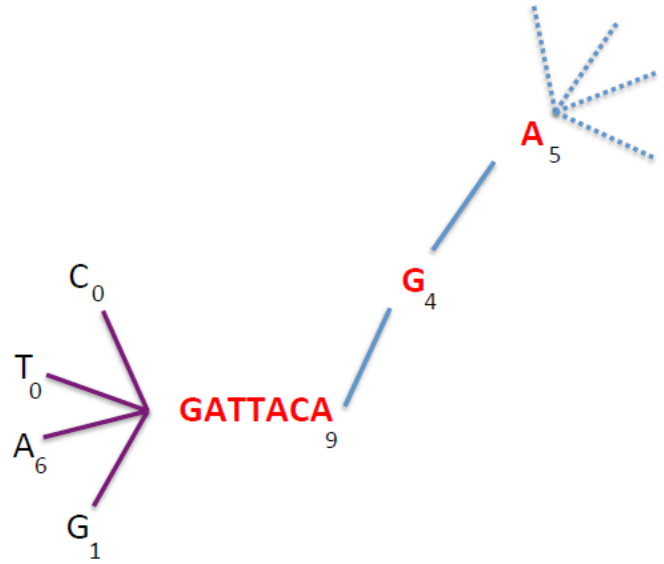
Algoritmo utilizado por Inchworm



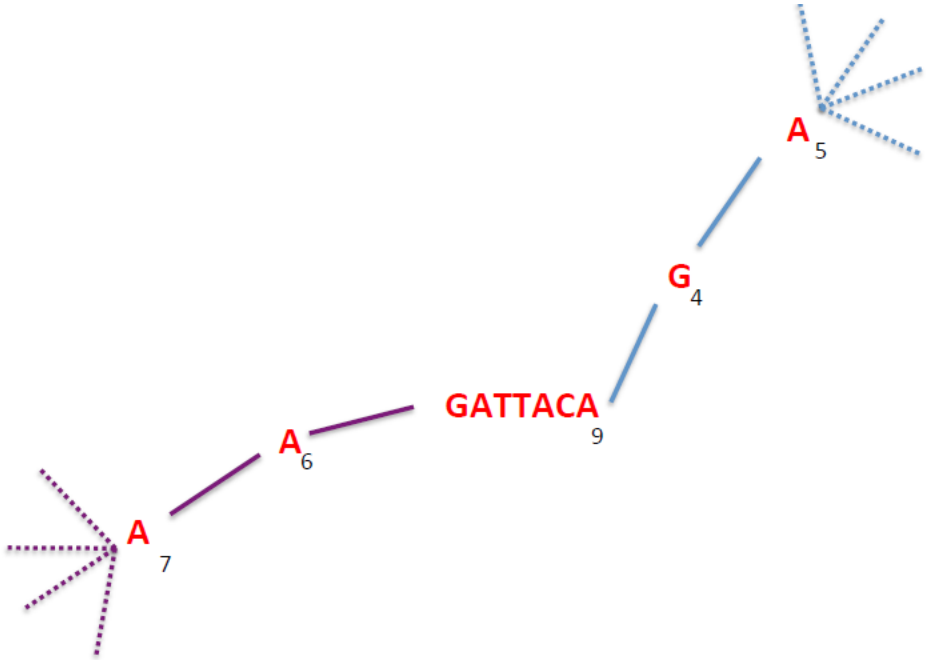
Algoritmo utilizado por Inchworm



Algoritmo utilizado por Inchworm



Algoritmo utilizado por Inchworm

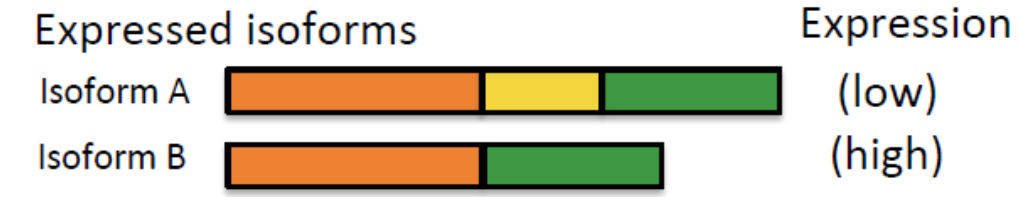


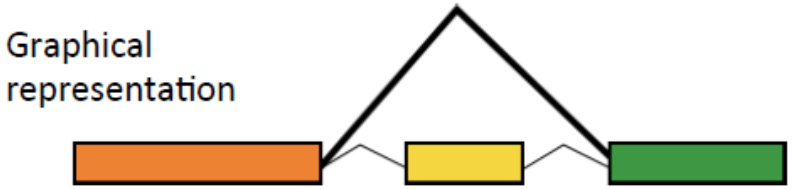
Contig reportado: ....AAGATTACAGA....

Kmers que fueron ensamblados se retiran de la tabla y se repite el proceso

Contigs para transcritos con splicing alternativo



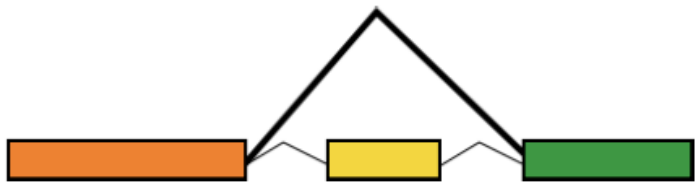


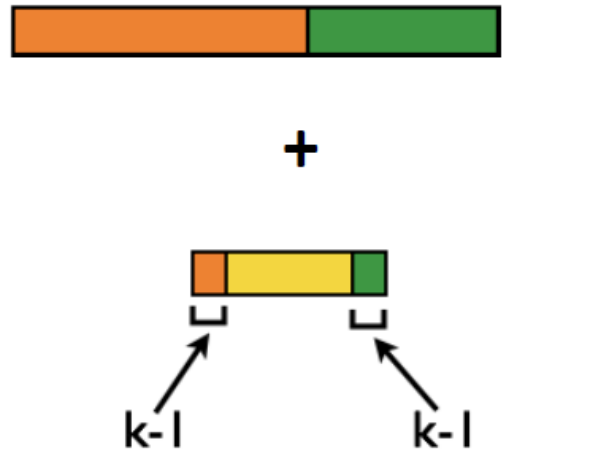


Inchworm Reporta los siguientes contigs



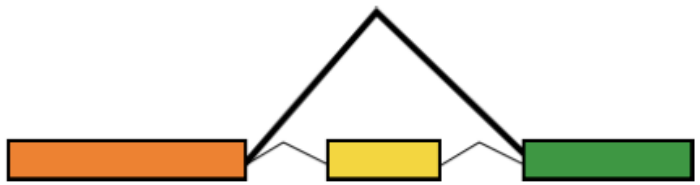
Contigs para transcritos con splicing alternativo

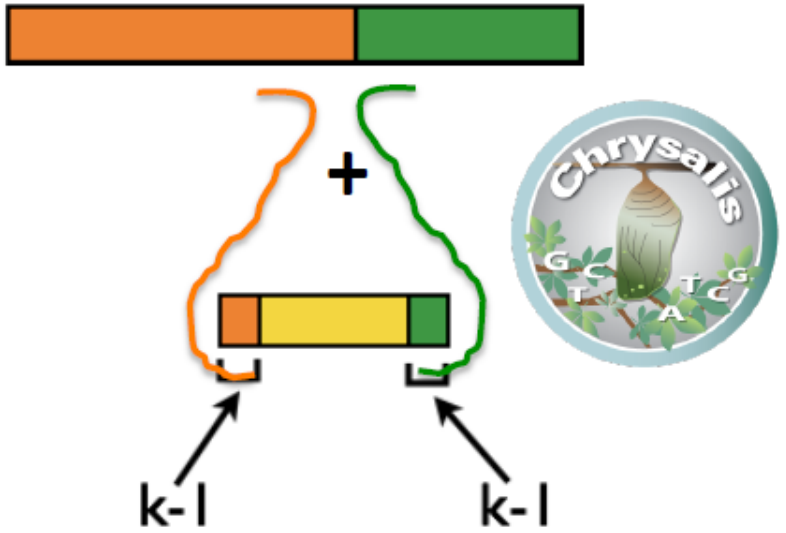




Secuencias en común

Contigs para transcritos con splicing alternativo → Chrysalis!





Chrysalis usa la superposición de las regiones (k-1) y los reads para unir contigs relacionados

Chrysalis integra isoformas y construye los gráficos de bruijn

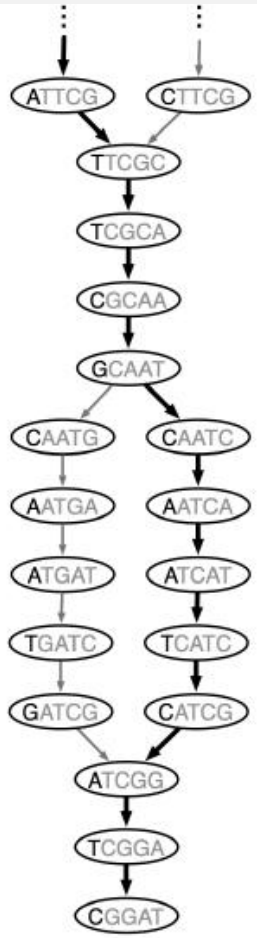
Chrysalis

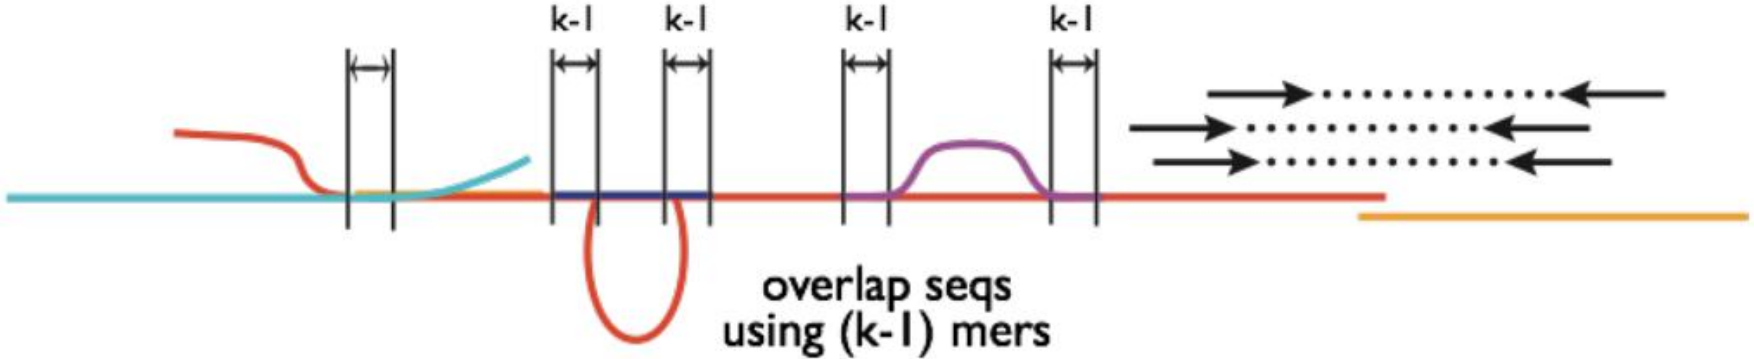
>a121:len=5845
>a122:len=2560
>a123:len=4443
>a124:len=48
>a125:len=8876
>a126:len=66



Integra isoformas solo sí:
Existe sobrelape perfecto k-1 (clusters)
Y existe un mínimo número de reads que caigan en esa union

Construcción de gráfico De Bruijn (uno por gen, idealmente)





Butterfly procesa los gráficos y reporta las isoformas

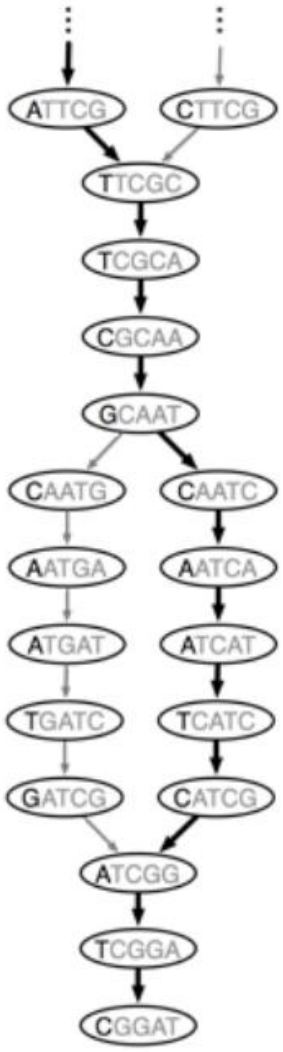
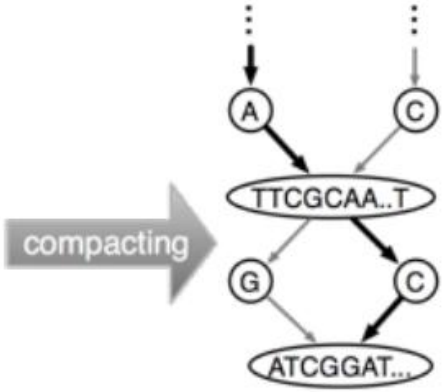
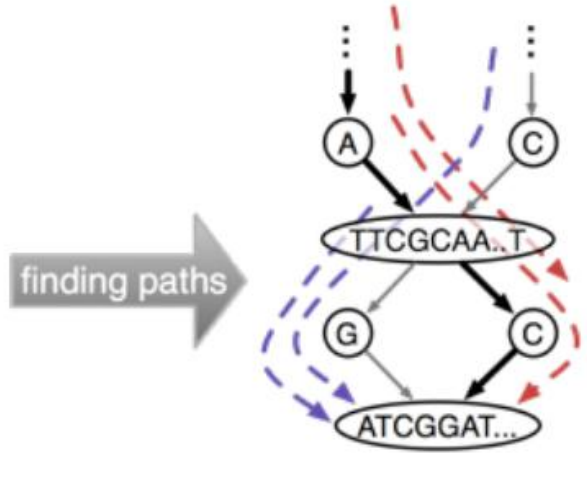


Gráfico De Bruijn

Butterfly



Compactar gráficos



Compactar gráficos con reads

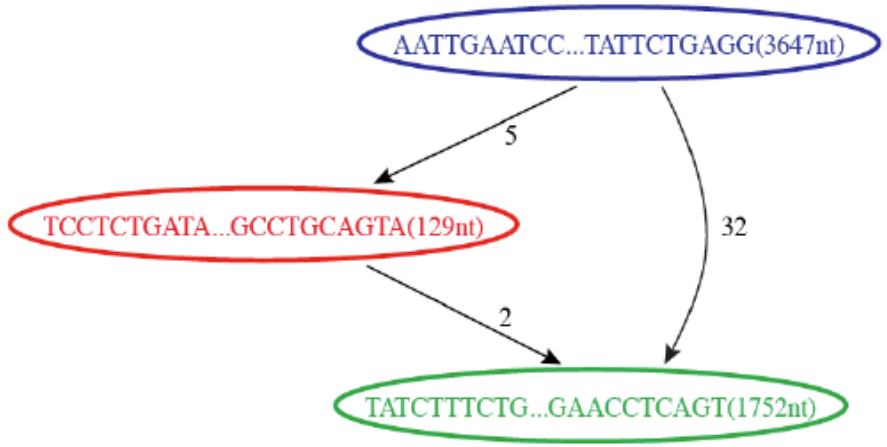
..CTTCGCAA..TGATCGGAT...

..ATTCGCAA..TCATCGGAT...

Secuencias (isoformas)

Ejemplo de reconstrucción de splicing alternativo

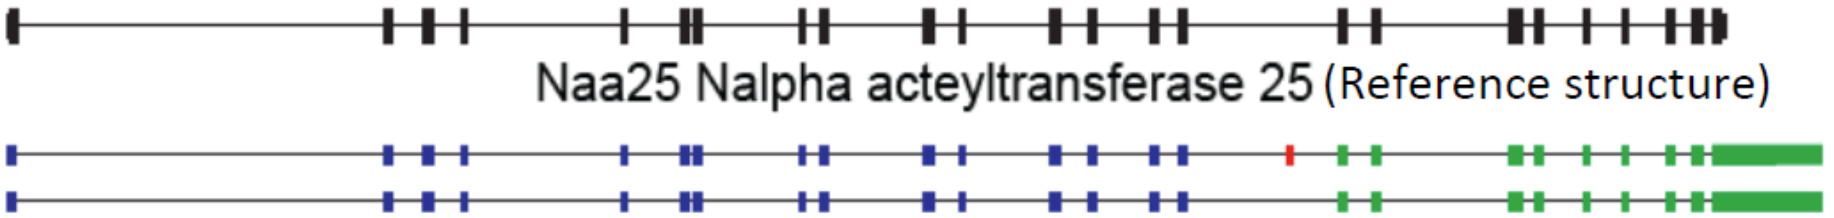
Butterfly's Compacted Sequence Graph



Reconstructed Transcripts



Aligned to Mouse Genome





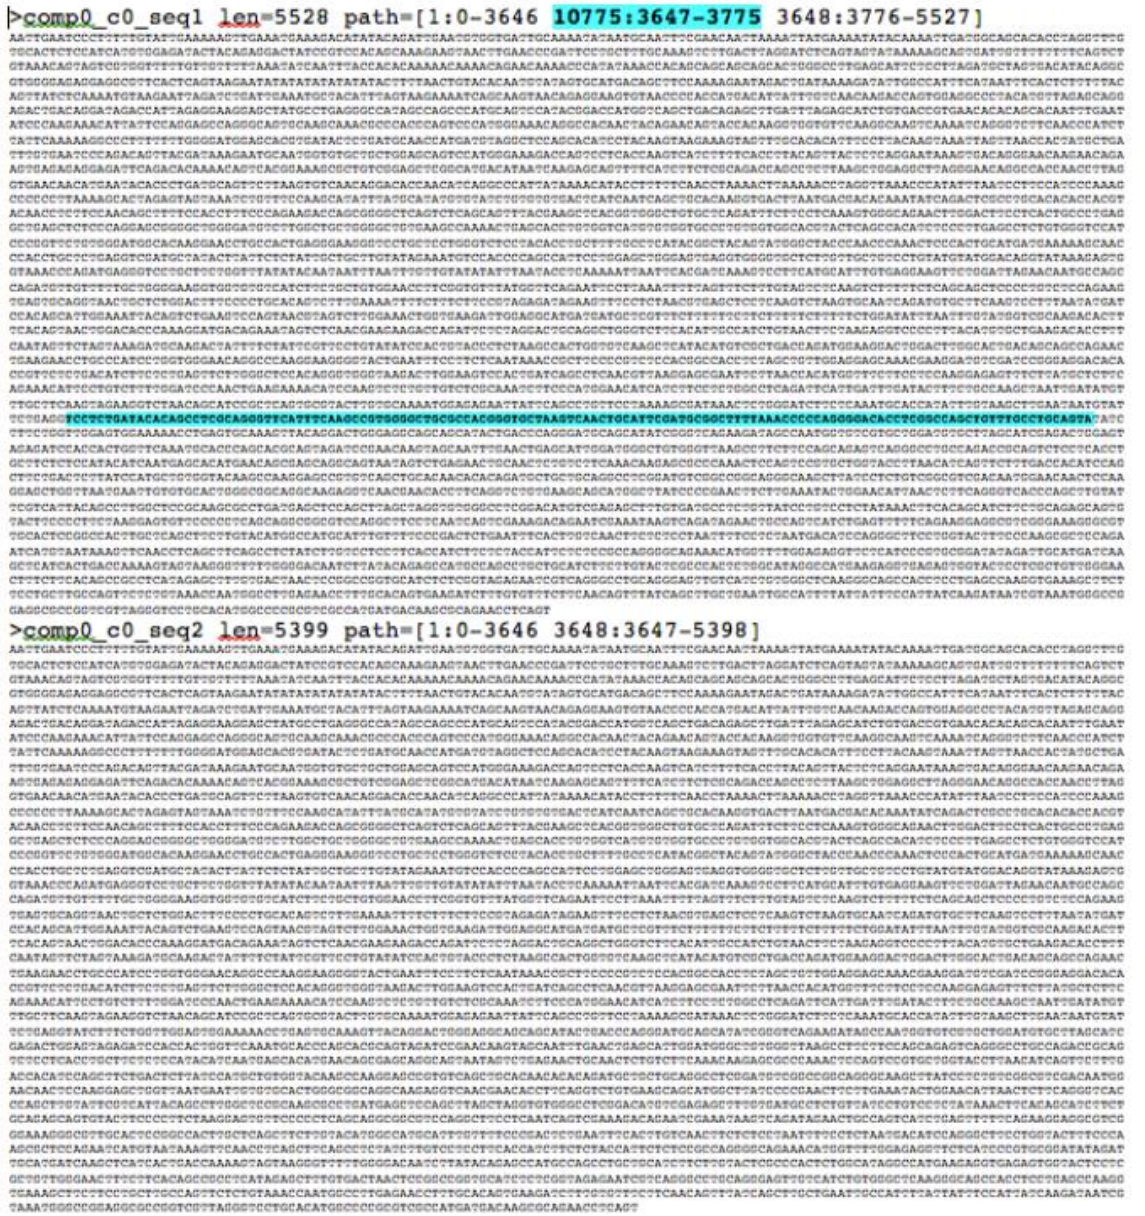
Ensamble entregado por TRINITY

```
>TRINITY_DN1000|c115_g5_i1 len=247 path=[31015:0-148 23018:149-246]
AATCTTTTTTGGTATTGGCAGTACTGTGCTCTGGGTAGTGATTAGGGCAAAAGAAGACAC
ACAATAAAGAACCAGGTGTTAGACGTCAGCAAGTCAAGGCCTTGGTTCTCAGCAGACAGA
AGACAGCCCTTCTCAATCCTCATCCCTTCCCTGAACAGACATGTCTTCTGCAAGCTTCTC
CAAGTCAGTTGTTCACAGGAACATCATCAGAATAAATTTGAAATTATGATTAGTATCTGA
TAAAGCA
```

'TRINITY_DN1000|c115_g5_i1:
Trinity read cluster 'TRINITY_DN1000|c115'
gene 'g5'
isoform 'i1'

"path=[31015:0-148 23018:149-246]"

node '31015' → sequence range 0-148
node 23018 → sequence range 149-246
Los Nodos pueden compararse entre isoformas para averiguar regiones únicas



Evaluación de la calidad del ensamble

- **Examinar la representación de los reads de RNA-seq en el ensamble**
  Al menos 80% (ideal de 90 a 95%) de los reads deben mapear en el ensamble.
  El resto corresponde a isoformas bajamente expresadas que no logran ser ensambladas

- **Evaluar la representación de proteínas conocidas que fueron completamente reconstruidas por el ensamble**
  Blast el ensamble contra una base de datos de proteínas conocidas

- **Explorar reconstrucción completa en un contexto de conservación de ortólogos**
  Usando el programa **BUSCO** (genes ortólogos esperados en un contexto)

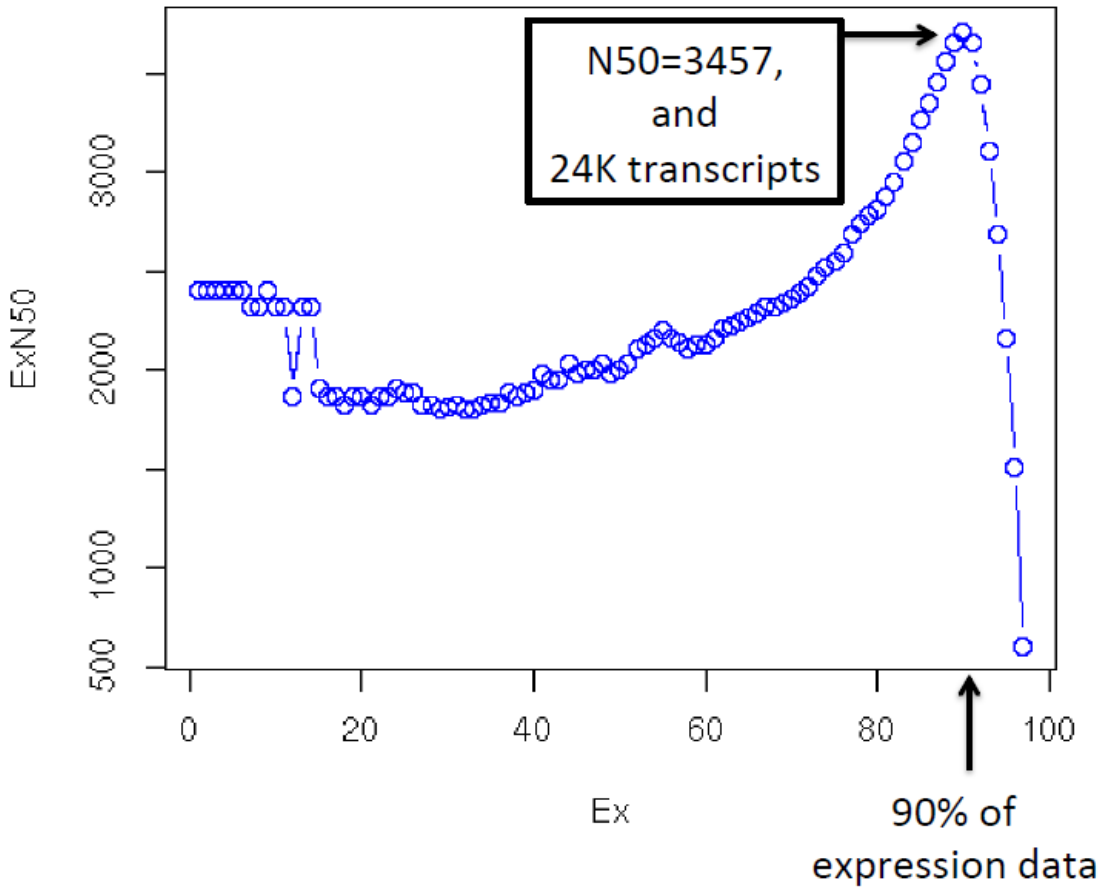
- **Calcular el E90N50 de la longitud de los transcritos ensamblados**
  Cálculo de la mediana de la longitud de los transcritos ensamblados ordenados por talla.
  Se utiliza sólo los transcritos representando un 90% de la expresión

- **Usar TransRate para generar varias estadísticas**

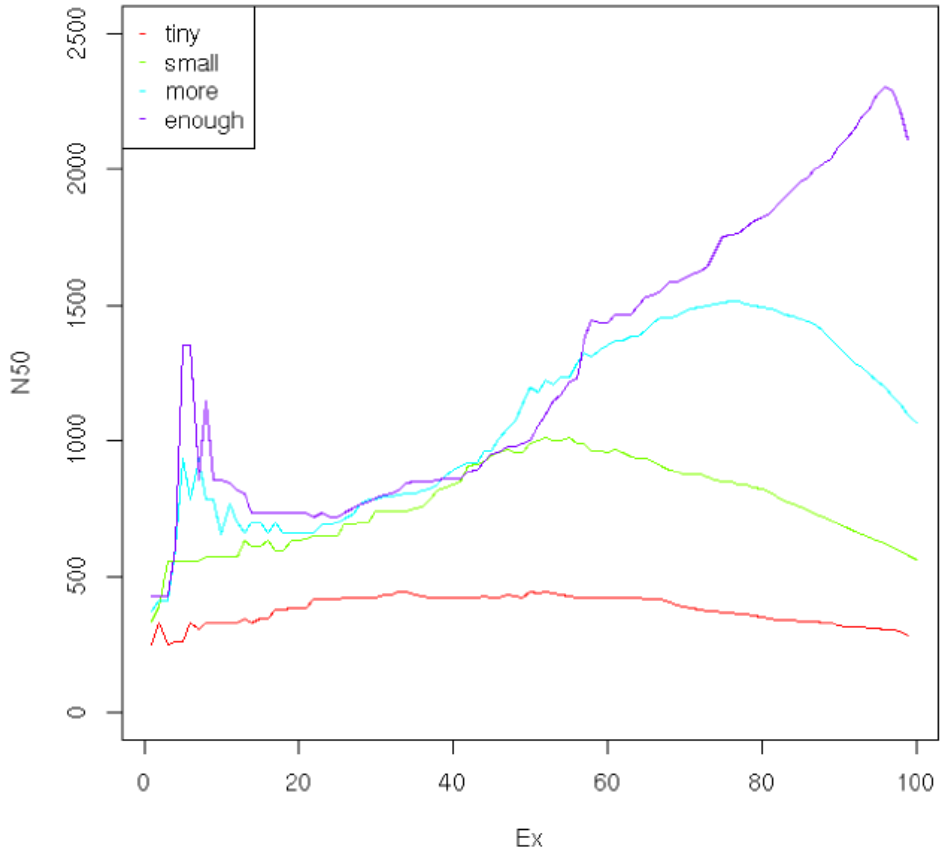
Calculo de E90N50 (ExN50)

Calcular N50 en base a los transcritos mayormente expresados

- Ordenar contigs por su valor de expresión, descendente
- Calcular N50 calcular dato un mínimo % del total de la expresión => ExN50



N50 cambia al aumentar la cobertura

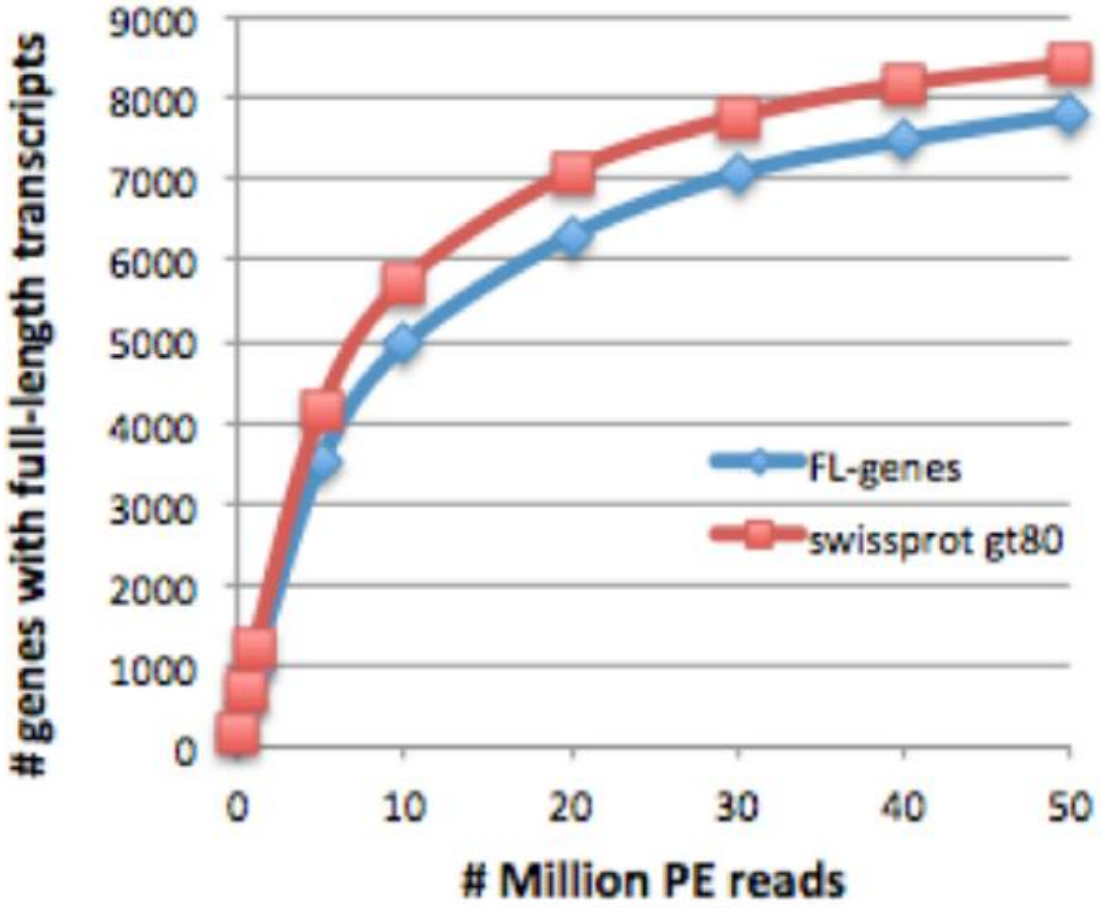


Millones

Miles

Detección de transcritos completos a través de BLASTx





Have you sequenced deeply enough?

* Mouse transcriptome

Haas et al. Nat. Protoc. 2013

Detección de transcritos completos en base a conservación

UNIVERSITÉ DE GENÈVE
FACULTÉ DE MÉDECINE

Zdobnov's Computational Evolutionary Genomics group

CEGG Home | OrthoDB *v9* | BUSCO *v2*

BUSCO v2

Assessing genome assembly and annotation completeness with **B**enchmarking **U**niversal **S**ingle-**C**opy **O**rthologs

About BUSCO

BUSCO *v2* provides quantitative measures for the assessment of genome assembly, gene set, and transcriptome completeness, based on evolutionarily-informed expectations of gene content from near-universal single-copy orthologs selected from OrthoDB *v9*.

BUSCO assessments are implemented in open-source software, with a large selection of lineage-specific sets of Benchmarking Universal Single-Copy Orthologs. These conserved orthologs are ideal candidates for large-scale phylogenomics studies, and the annotated BUSCO gene models built during genome assessments provide a comprehensive gene predictor training set for use as part of genome annotation pipelines.

Detección de transcritos completos en base a conservación



BUSCO v2

Assessing genome assembly and annotation completeness with **B**enchmarking **U**niversal **S**ingle-**C**opy **O**rthologs

#Summarized BUSCO benchmarking for file: Trinity.fasta
#BUSCO was run in mode: trans

Summarized benchmarks in BUSCO notation:
C:88%[D:53%],F:4.5%,M:7.3%,n:3023

Representing:
1045 Complete Single-copy BUSCOs
1617 Complete Duplicated BUSCOs
139 Fragmented BUSCOs
222 Missing BUSCOs
3023 Total BUSCO groups searched

Ahora demos paso a la parte práctica

Ensamblemos un transcriptoma usando trinity